ResearchGate

See discussions, stats, and author profiles for this publication at: https://www.researchgate.net/publication/342040525

Algoritmos Genéticos

Method · June 2020

DOI: 10.13140/RG.2.2.11789.97761

CITATIONS
0

READS
874

1 author:



Robinson F. Alvarez
University of São Paulo
6 PUBLICATIONS **22** CITATIONS

SEE PROFILE

All content following this page was uploaded by Robinson F. Alvarez on 09 June 2020.

The user has requested enhancement of the downloaded file.

Algoritmos Genéticos

Robinson Franco A.[1]

[1]*Departamento de Física, Universidad del Valle, A.A. 25360, Cali, Colombia*

(Dated: 18 Septiembre 2009)

Los algoritmos genéticos son métodos de búsqueda dirigida basados en probabilidad. Estos algoritmos están inspirados en los fenómenos biológicos de selección y recombinación natural que simulan la evolución de una población o grupos de individuos que, a la vez, son posibles soluciones a un determinado problema. En este trabajo se presentan los fundamentos básicos del algoritmo genético simple (AGS). Posteriormente, se efectua la simulación de un AGS en VisualBasic 5.0 que pretende maximizar una función dada con el fin de corroborar la eficiencia de dicho algoritmo.

I. INTRODUCCIÓN

Los algoritmos genéticos imitan los principios de la evolución biológica tales como la reproducción, la recombinación genética y la selección para aplicarlos en programas computacionales y buscar soluciones a problemas de ingeniería [5]. Un algoritmo genético opera sobre un conjunto de candidatos (posibles soluciones o genotipos) llamado población. Este conjunto usualmente se codifica en cadenas binarias (fenotipos) que tienen longitud fija y se evalúan de acuerdo a una función objetivo que indica el nivel de adaptación que ha logrado el individuo (o solución) después de varias generaciones (iteraciones). La población inicial se crea aleatoriamente y en cada generación las cadenas se reproducen de manera selectiva, de acuerdo a su aptitud, y son modificadas a través de operadores genéticos de cruce y mutación entre otros. La operación de selección asegura que sobrevivan los individuos mas adaptados, mientras que la recombinación genética garantiza que la información fluya a través de las cadenas de individuos. Como resultado apreciable se tiene que el algoritmo usualmente converge hacia una población cuyos miembros representan soluciones cercanas al óptimo, según requerimientos previamente establecidos [2, 5].

II. FUNDAMENTO DEL ALGORITMO GENÉTICO

El funcionamiento de un algoritmo genético estándar o simple (AGS) cumple los siguientes pasos [5]:

1. Se genera aleatoriamente una población inicial de N individuos que representan las posibles soluciones del problema. En caso de no hacerlo aleatoriamente es importante garantizar que dentro de la población inicial se tenga la diversidad estructural de estas soluciones para tener una representación de la mayor parte de la población posible o al menos evitar la convergencia prematura.

2. Después de saber la aptitud de cada individuo dada por la ecuación (1), se procede a elegir los individuos que serán cruzados en la siguiente generación, véase figura 2.

3. Los individuos con mejor aptitud tienen mayor probabilidad de ser seleccionados.

4. El cruzamiento es el principal operador genético, representa la reproducción sexual, opera sobre dos individuos a la vez para generar dos descendientes donde se combinan las características de ambos individuos padres.

5. El algoritmo genético se deberá detener cuando se alcance la solución óptima, pero ésta generalmente se desconoce, por lo que se deben utilizar otros criterios de detención. Normalmente se usan dos criterios: correr el algoritmo genético con un número máximo de iteraciones (generaciones) o detenerlo cuando no haya cambios en la población (homogenizacíon del resultado). De no ser así, el algoritmo genético se devuelve al punto dos.

El problema de selección de variables es un problema de optimización, ya que lo que se quiere es encontrar, bajo alguna heurística, el subconjunto de variables que potencialicen las diferenciaciónes y las semejanzas de objetos de clases diferentes y de la misma clase respectivamente [1, 2, 5].

A. La Función objetivo

La función objetivo es una de las partes mas importantes que forman un algoritmo genético porque en ella está presente el atributo o atributos que se desean optimizar. Con esta función se evaluará cada individuo y en correspondencia con el comportamiento de este, se le asignará un valor que caracteriza su aptitud para realizar la tarea en cuestión [2, 5].

B. Operadores genéticos

Usualmente se utilizan en este tipo de algoritmos tres operadores básicos: selección, cruce y mutación.

1. Selección

La selección es el operador mediante el cual el individuo se copia proporcionalmente a su aptitud para solucionar un problema, con vista a formar un conjunto intermedio de individuos a los que se les aplicarán los demás operadores. Seleccionar individuos acorde a su *fitness* significa que los individuos con mayor idoneidad tienen una mayor probabilidad de contribuir con una o mas copias en la siguiente generación. La función objetivo es la que determina el *fitness* de cada individuo. Este operador se aplica de tal manera que se le da la mayor probabilidad de seleccionarse a los individuos más aptos. Este método llamado usualmente *selección proporcional* se aplica a través de la siguiente ecuación:

$$Pr(I_i^t) = \frac{fitness(I_i^t)}{\sum_{j=1}^{n} fitness(I_j^t)} \quad (1)$$

donde $Pr(I_i^t)$ es la probabilidad de selección proporcional correspondiente al i-ésimo individuo en el instante t. Después de obtener la probabilidad de selección para cada individuo se procede a efectuar la selección. El criterio de selección tiene muchas variantes como por ejemplo: el criterio de selección *jerárquico*, por *torneo* o el de *muestreo universal estocástico* teniendo este ultimo mayor aceptación entre los diseñadores de algoritmos genéticos. Buckles [3] introduce este método, el cual utiliza un único giro de la ruleta siendo los sectores circulares proporcionales a la función objetivo. Los individuos son seleccionados a partir de marcadores, véase Figura 1, igualmente espaciados y con comienzo aleatorio [1, 2, 5].

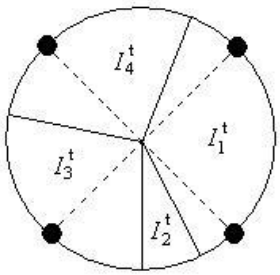


FIG. 1: Método selección de padres denominado muestreo universal estocástico. El individuo I_1^t se escoge dos veces, mientras que los individuos I_3^t e I_4^t son elegidos una única vez.

2. Cruce

El cruce se realiza aleatoriamente entre individuos que han sido seleccionados con una probabilidad de cruce, o Pc. La posición en que se realiza el cruce también se decide de forma aleatoria, esta posición está dada por un número entero entre 1 y $Lc - 1$ donde Lc se refiere al largo de la cadena. Frecuentemente a los individuos seleccionados para cruzarse se les denomina padres y los nuevos individuos formados por el cruce se les llama hijos [2, 5]. Una forma de aplicar este operador es el cruce sencillo o simple como se muestra en la figura 2.

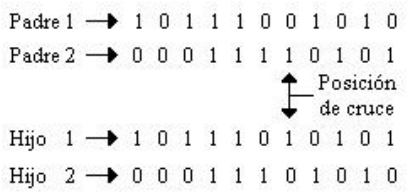


FIG. 2: Método de cruce sencillo.

En este punto del algoritmo se pueden seguir varios caminos:

- Mantener el tamaño de la población fija, en la que los hijos sustituyen a los padres.
- Hacer una población en donde hay una mezcla de hijos y padres; esta población existirá temporalmente, porque siempre al empezar el algoritmo el tamaño de la población debe ser fijo.

3. Mutación

La mutación consiste en recorrer cada uno de los nuevos individuos *hijos* y cambiar aleatoriamente, según lo determine la probabilidad de mutación (Pm), su valor actual por su complemento (en codificación binaria esto quiere decir que hay que cambiar un bit de 1 a 0 o viceversa). La mutación debe implementarse de tal forma que garantice la variabilidad genética pero que no afecte demasiado la aptitud de un individuo para solucionar un problema [5]. En un algoritmo genético, la selección y el cruce juegan un papel fundamental. Se debe tener en cuenta que siempre se trabaja con una probabilidad de cruce muy alta, lo cual se fundamenta en que el intercambio de soluciones valiosas es la forma idónea de llegar a la mejor solución. Por su parte, la mutación es un operador secundario en el algoritmo genético y siempre tiene una probabilidad muy baja. Se utiliza para evitar que se pierda alguna característica importante en el individuo [2, 5].

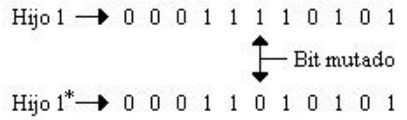


FIG. 3: Individuo tras el cruce y la mutación.

III. MODELO TEÓRICO

El modelo matemático usual para describir el comportamiento de los algoritmos genéticos está basado en el *teorema del esquema*. Éste fue planteado originalmente por Holland [1] para el AGS, y se caracteriza por utilizar selección proporcional y cruzamiento de un punto, entre otras cosas.

A. Esquemas

Se ha creado una notación para los conjuntos de cadenas binarias mediante cadenas compuestas de tres símbolos, es decir: 0,1,*. Considérese un conjunto de cadenas que poseen valores comunes en ciertas posiciones. Para construir la cadena que denota este conjunto, basta colocar en las posiciones donde las cadenas coinciden el valor explicito que tienen, y en las posiciones donde los valores no coinciden se coloca un *. De esta manera, por ejemplo, 1*0* denota el conjunto (1000, 1001, 1100, 1101). A las cadenas compuestas de 1, 0 y * se les denomina esquemas. El número de posiciones con valor explicito de un esquema H se denomina orden del esquema y se denota por $o(H)$. La distancia entre la primera y la ultima posición explicita se denomina *longitud de definición* o *defining length* y se denota como $\delta(H)$. En la figura 4 se ilustran estas definiciones.

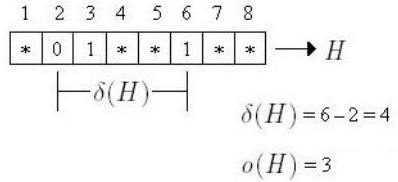


FIG. 4: Orden y longitud de definición en un esquema. La longitud de definición es el número de posiciones que hay entre el primer y ultimo bit definido y el orden de definición es la suma del número de bits definidos en un esquema.

1. *Efecto de la selección aplicado a los esquemas*

Supóngase que en la población de tamaño N de generación t de un algoritmo genético existen k representantes del esquema H y que f_1, f_2, f_3,...., f_k son los valores de la función de adaptación para los k representantes. Si se selecciona aleatoriamente un miembro de la población usando el mecanismo de la ruleta, la probabilidad de que éste sea el i-ésimo representante del esquema H es:

$$P_i = \frac{f_i}{\sum_{j=1}^{N} f_j}. \tag{2}$$

Entonces, la probabilidad de seleccionar algún representante del esquema H es:

$$P_H = \frac{f_1}{\sum_{j=1}^{N} f_j} + \frac{f_2}{\sum_{j=1}^{N} f_j} + ... + \frac{f_k}{\sum_{j=1}^{N} f_j}, \tag{3}$$

o tambien:

$$P_H = \frac{f_1 + f_2 + ... + f_k}{\sum_{j=1}^{N} f_j}. \tag{4}$$

Sea $\bar{f}(H)$ el valor de adaptación promedio de los representantes del esquema H y $m(H,\ t)$ el número de representantes del esquema en la población de generación t. Por definición:

$$\bar{f}(H) = \frac{f_1 + f_2 + ... + f_k}{m(H,t)}, \tag{5}$$

de donde:

$$f_1 + f_2 + ... + f_k = \bar{f}(H)m(H,t), \tag{6}$$

sustituyendo en la ecuación (4), se obtiene:

$$P_H = m(H,t)\frac{\bar{f}(H)}{\sum_{j=1}^{N} f_j}, \tag{7}$$

que denota la probabilidad de seleccionar un representante del esquema H en la población de generación t. Sea $\bar{f}$ el valor promedio de adaptación de la población en la generación t:

$$\bar{f} = \frac{\sum_{j=1}^{N} f_j}{N}, \tag{8}$$

seleccionando N individuos de la población de generación t para la generación $t+1$, el valor esperado de individuos seleccionados del esquema H es:

$$m_{sel}(H,t+1) = Nm(H,t)\frac{\bar{f}(H)}{\sum_{j=1}^{N} f_j},$$

o tambien:

$$m_{sel}(H,t+1) = m(H,t)\frac{\bar{f}(H)}{\bar{f}}. \tag{9}$$

Hay que reiterar que las expresiones presentadas son válidas sólo para el tipo de selección proporcional o de ruleta (no son ciertas en general).

2. *Efecto del cruce tras la selección*

Supóngase ahora que se aplica algún tipo de cruzamiento con cierta probabilidad p_c sobre los individuos previamente seleccionados. Considérese lo que ocurriría con aquellas cadenas pertenecientes a un cierto esquema H. Algunas de estas cadenas se cruzarían con otras de

forma tal que la cadena resultante ya no sería representante del esquema H, es decir, el esquema se rompería. Otras no serían seleccionadas para cruzarse y simplemente pasarían intactas a la siguiente generación y habría otras más que originalmente no eran representantes del esquema y que al cruzarse generarían cadenas de H. El valor esperado de cadenas representantes de H que han sido seleccionadas y a las que no se les aplica cruzamiento es:

$$(1-p_c)m(H,t)\frac{\bar{f}(H)}{\bar{f}}. \tag{10}$$

Sea p_r la probabilidad de ruptura del esquema H bajo el tipo de cruzamiento que esté siendo utilizado. El valor esperado del número de cadenas representantes de H que fueron seleccionadas y permanecen en el esquema después de aplicárseles cruzamiento es:

$$p_c\left[m(H,t)\frac{\bar{f}(H)}{\bar{f}}(1-p_r)\right]. \tag{11}$$

A la expresión anterior habría que hacerle una pequeña corrección para considerar aquellas cadenas que originalmente estaban fuera del esquema y que después de cruzarlas generaron representantes de él. Sea g el número de cadenas ganadas por el esquema H mediante el mecanismo descrito, reescribiendo la anterior expresión se tiene:

$$p_c\left[m(H,t)\frac{\bar{f}(H)}{\bar{f}}(1-p_r)+g\right]. \tag{12}$$

El valor esperado del número total de representantes del esquema H, tras haber efectuado la selección y el cruzamiento es:

$$m_{sel,cru}(H,t+1) = (1-p_c)m(H,t)\frac{\bar{f}(H)}{\bar{f}} + p_c\left[m(H,t)\frac{\bar{f}(H)}{\bar{f}}(1-p_r)+g\right], \tag{13}$$

si se excluye g, es claro notar que:

$$m_{sel,cru}(H,t+1) \geq (1-p_c)m(H,t)\frac{\bar{f}(H)}{\bar{f}} + p_c\left[m(H,t)\frac{\bar{f}(H)}{\bar{f}}(1-p_r)\right], \tag{14}$$

es decir:

$$m_{sel,cru}(H,t+1) \geq m(H,t)\frac{\bar{f}(H)}{\bar{f}}(1-p_cp_r). \tag{15}$$

3. Efecto de la mutación tras la selección y el cruce

Por último, hay que considerar el efecto de las mutaciones. Supóngase que una mutación se aplica con probabilidad p_m y que tiene el efecto de invertir un bit (cambiar un 1 por un 0 ó viceversa). Para que una cadena representante del esquema H permanezca en él tras una mutación, debe ocurrir que ninguno de los bits definidos del esquema sea invertido. Recuérdese que el número de bits definidos del esquema es $o(H)$. La probabilidad de que un bit no sea invertido por una mutación es $1-p_m$, así que la probabilidad de que ninguno de los bits definidos sea invertido, suponiendo que el invertir cada bit es un evento independiente, es:

$$(1-p_m)^{o(H)}, \tag{16}$$

Por lo tanto la ecuación (15) se ve afectada por este factor, quedando de la siguiente forma:

$$m_{sel,cru,mut}(H,t+1) \geq m(H,t)\frac{\bar{f}(H)}{\bar{f}}(1-p_cp_r)\,(1-p_m)^{o(H)}. \tag{17}$$

A esta expresión se le conoce como el *teorema de los esquemas* y proporciona una cota inferior del número esperado de individuos que se asocian con el esquema H en la siguiente generación, expresado en función del número de individuos que se asocian con el esquema en la actual generación, asi como de la adaptación del esquema relativa a la adaptación media de la población, el orden y la longitud del esquema, la longitud de las cadenas binarias, asi como las probabilidades de cruce y mutación. Tal y como se desprende de la expresión anterior, esquemas cortos, de bajo orden y con una adaptación al problema superior a la adaptación media, se espera que a medida que evoluciona el algoritmo genético, obtengan un incremento exponencial en el número de individuos que se asocian con los mismos. A ésto se le denomina la hipotesis de los bloques constructivos (*building blocks*) (HBC).

IV. EXPERIMENTACIÓN Y RESULTADOS

Se diseñó un programa en VisualBasic versión 5.0, con el fin de corroborar cualitativamente la efectividad de los algoritmos genéticos simples o (AGS). Este programa trata de maximizar una función la cual tiene unas características deseables para la aplicación de dicho algoritmo, es decir, solo tiene un máximo global; además, cuando x toma un valor muy grande $f(x)$ tiende a cero lo cual significa que no es necesario una población de individuos muy densa ya que para valores extrémales de x la función objetivo $f(x)$ se vera muy devaluada por lo que estos valores de x probablemente se verán descartados. La función objetivo comentada es:

$$f(x) = \frac{\alpha x^5}{e^{\beta x}+1}, \tag{18}$$

donde α y $\beta \in \Re$ y por defecto $\alpha = 0.00001$ y $\beta = 0.05$. En la figura 5 se muestra la población inicial generada aleatoriamente por el programa, la población consta de seis individuos. La primera columna, de izquierda a

derecha, son los *genotipos* o codificación binaria de dichos individuos. La segunda columna muestra los *fenotipos* o valor decimal correspondiente a cada *genotipo*. La tercera columna es la evaluación de la función objetivo para cada individuo, $f(x)$. La cuarta columna muestra la probabilidad que tiene cada individuo de ser seleccionado, (PS) y la quinta columna es la probabilidad acumulada, (PA). En este caso se utilizó $P_c = 0.8$ y $P_m = 0.05$.

POBLACIÓN INICIAL				
Genotipo	Fenotipo	F(x)	PS	PA
(1) 01110110	118	625,006	0,29786	0,29786
(2) 11000000	192	176,705	0,08421	0,38207
(3) 10101001	169	294,817	0,14050	0,52257
(4) 00011100	28	34,045	0,01622	0,53879
(5) 10011100	156	378,397	0,18033	0,71912
(6) 01010000	80	589,372	0,28088	1,00000

FIG. 5: Población Inicial.

Después de 30 iteraciones se homogenizó la población, este fue el criterio de parada. Esto se puede notar en la siguiente tabla:

SELECCIÓN / Población actual				
Genotipo	Fenotipo	F(x)	PS	PA
(1) 01100100	100	669,285	0,16667	0,16667
(2) 01100100	100	669,285	0,16667	0,33334
(3) 01100100	100	669,285	0,16667	0,50001
(4) 01100100	100	669,285	0,16667	0,66668
(5) 01100100	100	669,285	0,16667	0,83335
(6) 01100100	100	669,285	0,16667	1,00002

FIG. 6: Población final tras aplicar 30 veces el proceso de selección cruce y mutación.

Se puede mostrar gráficamente el efecto de este método. Los puntos de colores corresponden a la evolución de cada individuo desde el primero al sexto en orden descendente. Se puede notar claramente como estos puntos, que inicialmente están dispersos, se van concentrando alrededor del punto máximo que, por otros métodos numéricos, debe estar entre: $100.65217 < x_{max} < 100.65218$.



FIG. 7: Gráfica de 10x100 que muestra la convergencia evolutiva de los individuos.

V. CONCLUSIONES

1. En problemas reales en los que se aplican los algoritmos genéticos, existe la tendencia a la homogenización de la población, es decir a que todos los individuos de la misma sean idénticos. Esto impide que el algoritmo siga explorando nuevas soluciones, con lo que podemos quedar estancados en un maximo o mínimo local no muy bueno. Existen técnicas para contrarrestar esta *deriva genética*. El mecanismo más elemental, aunque no siempre suficientemente eficaz, es introducir una mutación tras la selección y el cruce. Una vez se realiza la selección y el cruce se escoge un número determinado de bits de la población y se alteran aleatoriamente.

2. En el desempeño de un algoritmo genético es importante seleccionar adecuadamente los parámetros de control, la probabilidad de cruce debe ser alta para garantizar el intercambio de información genética de calidad entre los mejores individuos. La probabilidad de mutación debe ser baja y como criterio debe afectar a los individuos de una población de la menor manera posible de modo que solo cumpla un papel secundario para evitar perdida de características competentes en algún individuo.

3. El tamaño de la población incide sobre los resultados; poblaciones muy grandes garantizan mayor probabilidad de tener mejores soluciones, pero sacrifican la velocidad de ejecución del algoritmo; por tanto, se debe lograr un consenso. La función objetivo debe seleccionarse de manera adecuada para garantizar la calificación correcta de los individuos.

4. La capacidad de los algoritmos genéticos para tratar simultáneamente varias soluciones, implica, por tanto, su potencialidad para determinacíon y tratamiento simultaneo de varios conjuntos de parámetros óptimos.

5. Se evidencian las ventajas sobre todo desde el punto de vista computacional, dada la rápida convergencia del algoritmo, a veces en reducido número de generaciones o iteraciones.

[1] Holland, J.H., Adaptation in Natural and Artificial Systems, University of Michigan Press, 1975, 211 p.
[2] Goldberg, D.E., Genetic Algorithms in Search, Optimization and Machine Learning, Addison- Wesley Publishing Company, 1989, 412 p.
[3] Buckles, B.P., and Petry, F.E., Genetic Algorithms, IEEE Computer Society Press, 1992, 109 p.
[4] Richard J. Bauer, Jr, Genetic Algorithms and Investment Strategies, John Wiley and Sons, Inc , 1994, 308 p.
[5] Escuela de ingeniería eléctrica y electrónica de la universidad del valle. Rev. Energía y computación. Volumen VI, N 01, edición N 12. Cali, Colombia, 1997.

View publication stats